VIHATET5: Enhancing Hate Speech Detection in Vietnamese With a Unified Text-to-Text Transformer Model

Nhóm 11:
Phạm Thị Ngọc Bích - 23520148
Trịnh Trân Trân - 23521624
Nguyễn Minh Bảo - 23520123

Trường Đại học Công nghệ Thông tin - ĐHQG-HCM

Ngày 27 tháng 12 năm 2025

Nội dung báo cáo

1. Giới thiệu tổng quan
2. Phương pháp thực nghiệm
3. Kết quả thực nghiệm
4. Phân tích và thảo luận
5. Tài liệu tham khảo

Nội dung báo cáo

1. **Giới thiệu tổng quan**
2. Phương pháp thực nghiệm
3. Kết quả thực nghiệm
4. Phân tích và thảo luận
5. Tài liệu tham khảo

Giới thiệu tổng quan

- **Tác giả:** Luan Thanh Nguyen (UIT).
- **Năm công bố:** 2024 (ACL Findings).
- **Tổng quan:** Đề xuất ViHateT5 — mô hình Unified Multi-task đầu tiên cho tiếng Việt, giúp xóa bỏ sự phân mảnh bằng cách hợp nhất các bài toán phát hiện ngôn từ thù ghét, độc hại và xác định vị trí thù ghét (Hate Spans) trong một hệ thống Text-to-Text duy nhất.

Giới thiệu tổng quan

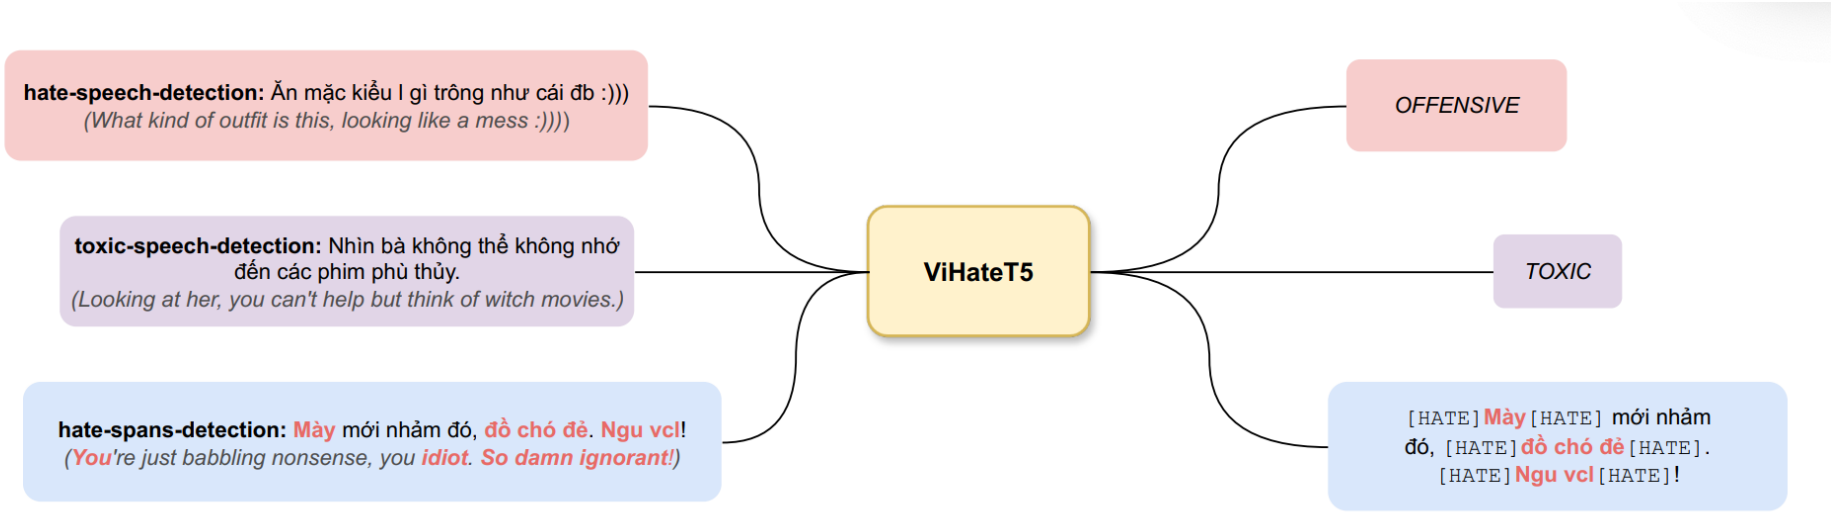

Hình 1: Tổng quan HSD-multitask ViHATET5

- **Kỹ thuật:** Sử dụng **Task Prefix** (Tiền tố).

Lý do thực hiện

- **Sự lỗi thời của dữ liệu cũ:** Các model hiện tại chủ yếu train trên Wikipedia, còn HSD xảy ra trên mạng xã hội với teencode, từ lóng.
- **Sự phức tạp hệ thống:** Trước đây, mỗi bài toán (Toxic, Hate, Spans) cần một model riêng.
- **Mục tiêu của nhóm:** Tái lập lại mô hình để kiểm chứng khả năng "hiểu" ngôn ngữ của kiến trúc T5 so với Encoder-only (BERT).

Nội dung báo cáo

1. Giới thiệu tổng quan
2. **Phương pháp thực nghiệm**
3. Kết quả thực nghiệm
4. Phân tích và thảo luận
5. Tài liệu tham khảo

Phương pháp thực nghiệm

- **Thu thập dữ liệu:** Thu thập 10.8 triệu bình luận từ diễn đàn VOZ để khai thác ngôn ngữ đời thực và các biểu cảm thù ghét.
- **Kiểm chứng và tiền xử lý:** Loại bỏ nhiễu và sử dụng mô hình ViSoBERT để gán nhãn tự động cho toàn bộ dữ liệu thô.
- **Huấn luyện mô hình:** Thực hiện tiền huấn luyện trên miền dữ liệu VOZ-HSD và tinh chỉnh đa nhiệm bằng kỹ thuật Task Prefix.

Bước 1: Thu thập dữ liệu

- **Nguồn dữ liệu:** Khai thác từ diễn đàn VOZ - nền tảng mạng xã hội có tính tự do ngôn luận cao nhất tại Việt Nam.
- **Phương pháp:** Sử dụng công cụ BeautifulSoup4.

No.	Parent Thread	N.o. Threads	N.o. Comments	Size (Uncompressed)
1	Random conversation	142,387	6,104,792	945MB
2	News	76,107	2,030,315	304MB
3	Sports	10,121	1,154,658	144MB
4	Cars	12,348	552,717	96MB
5	Movies - Music - Books	6,467	329,601	52MB
6	Bikes	5,093	258,728	41MB
7	Fashion	1,845	137,548	19MB
8	Food - Travel	3,492	136,649	19MB
9	Other hobbies	690	42,737	6MB
	Total	**258,550**	**10,747,745**	**1.66GB**

Hình 2: Sự phân bổ của các bình luận theo từng chủ đề

Bước 1: Thu thập dữ liệu

- **ViHSD:**
  - Quy mô: 33.400 bình luận thu thập từ Facebook và YouTube.
  - Nhiệm vụ: Phân loại câu với 3 nhãn: CLEAN, OFFENSIVE, HATE.
- **ViCTSD:**
  - Quy mô: 10.000 mẫu bình luận từ báo chí và mạng xã hội.
  - Nhiệm vụ: Phát hiện tính độc hại với 2 nhãn: NONE và TOXIC.
- **ViHOS:**
  - Quy mô: 11.056 bình luận chứa hơn 26.000 cụm từ độc hại.
  - Nhiệm vụ: Xác định vị trí từ ngữ thù ghét ở cấp độ âm tiết.

Mục đích: Sử dụng 3 bộ dataset này để so sánh hiệu năng của VIHATET5 với các mô hình đã có từ trước.

Bước 2: Kiểm chứng và tiền xử lý

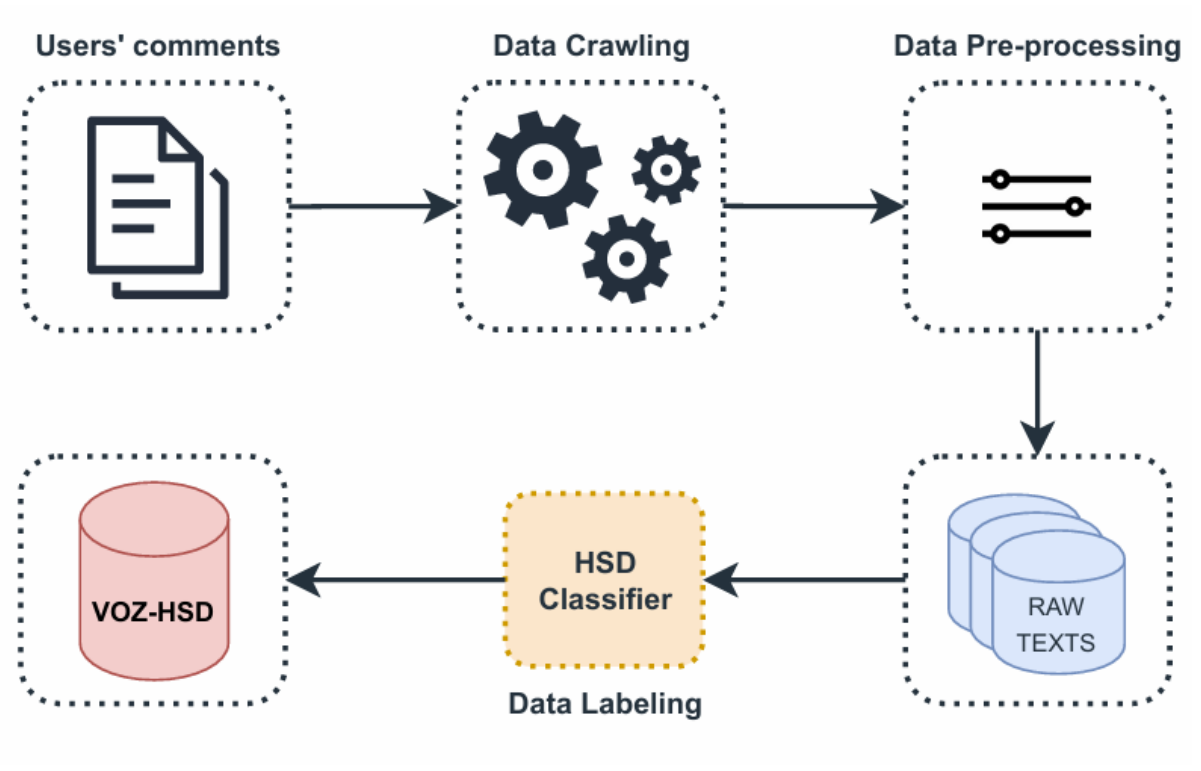

Hình 3: Sơ đồ quy trình gán nhãn dữ liệu VOZ-HSD

Bước 2: Kiểm chứng và tiền xử lý

Các bước để gán nhãn tự động:

1. **Chuẩn bị dữ liệu:** Chuyển đổi bộ dữ liệu ViHSD thành hai nhãn là NONE (Clean) và HATE (Offensive + Hate).
2. **Đối chứng mô hình:** Fine-tune đồng loạt 10 mô hình ngôn ngữ nhóm BERT đa ngôn ngữ và đơn ngữ tiếng Việt.
3. **Thiết lập thực nghiệm:** Huấn luyện thống nhất trong 3 epochs với lr 1×10^{-5} và batch size là 16.

Bước 2: Kiểm chứng và tiền xử lý

Bảng 1: Kết quả gán nhãn trên dữ liệu ViHSD

Mô hình	**Accuracy**	**Weighted F1**	**Macro F1**
Multilingual Pre-trained Models			
mBERT (cased)	0.9094	0.7548	0.7740
mBERT (uncased)	0.9102	0.7557	0.7784
DistilBERT	0.9115	0.7459	0.7754
XLM-R (base)	0.9189	0.7722	0.8028
XLM-R (large)	0.9204	0.7755	0.7968
Monolingual Pre-trained Models			
PhoBERT (base)	0.9231	0.7562	0.7764
PhoBERT (large)	0.9245	0.7895	0.7832
PhoBERT_v2 (base)	0.9216	0.7888	0.7810
viBERT	0.9117	0.7385	0.7771
ViSoBERT	**0.9296**	**0.8051**	**0.8128**

Bước 2: Kiểm chứng và tiền xử lý

Bảng 2: Phân phối sau khi dùng ViSoBERT gán nhãn

Label	**Samples (nhóm)**	**Ratio(%)**	**Samples (tác giả)**	**Ratio(%)**
Clean	10,223,138	95.12%	10,163,238	94.31%
Hate	524,595	4.88%	584,495	5.69%
Tổng cộng	**10,747,733**	**100%**	**10,747,733**	**100%**

Bước 2: Kiểm chứng và tiền xử lý

Bảng 3: Thiết lập thực nghiệm của tác giả (10.8M samples)

Ratio (Hate)	Số lượng	Phân phối nhãn
100%	584,495	100% Hate
50%	1,168,990	1:1 (Hate : Clean)
5.54%	**10,747,733**	**Phân phối gốc VOZ**

Bảng 4: Chiến lược thử nghiệm của nhóm tái lập (200K samples)

Chiến lược	Số lượng	Phân phối nhãn
Chiến lược 1	100,000	100% Hate
Chiến lược 2	200,000	1:1 (Hate : Clean)

Bước 3: Huấn luyện mô hình

Giai đoạn 1: Pre-training chuyên biệt (Domain-specific)

- **Phương pháp thực hiện:** Áp dụng kỹ thuật **Span Corruption** (T5 Masked Language Modeling).
- **Quy trình huấn luyện của tác giả:**
  - Thực hiện **Continual Pre-training** từ trọng số của mô hình **ViT5-base** trên 10.8 triệu bình luận từ tập **VOZ-HSD**.
  - **Cấu hình tham số:** Epochs: 20, Max length: 256, Optimizer: Adam ($lr = 5 \times 10^{-3}$), Batch size: 128.

Bước 3: Huấn luyện mô hình

Giai đoạn 1: Pre-training chuyên biệt (Domain-specific)

- **Nhóm thực hiện:**
  - Sử dụng mô hình ViT5-base và bắt đầu huấn luận trên dữ liệu VOZ-HSD (chỉ sử dụng 200,000 mẫu).
  - Cấu hình tham số: tối ưu bằng Adam, epochs: 20, max length: 256, lr: 5×10^{-3}, batch size: 128. (giống hoàn toàn của tác giả)

Bước 3: Huấn luyện mô hình

Giai đoạn 2: Fine-tuning đa nhiệm (Unified Multi-task)

- **Phương pháp:** Sequence-to-Sequence (Text-to-Text Generation).
- **Định dạng dữ liệu:** Sử dụng tiền tố để hợp nhất 3 tập dữ liệu vào một khung huấn luyện duy nhất:
  - **ViHSD:** `hate-speech-detection {văn bản}`
  - **ViCTSD:** `toxic-speech-detection {văn bản}`
  - **ViHOS:** `hate-spans-detection {văn bản}`
- **Tóm lại:** Chuyển đổi từ học tự giám sát (*Span Corruption*) sang học có giám sát đa nhiệm (*Seq2Seq*) để tối ưu hóa khả năng nhận diện sắc thái thù ghét.

Bước 3: Huấn luyện mô hình

Giai đoạn 2: Fine-tuning đa nhiệm (Unified Multi-task)

- **Tác giả thực hiện:**
  - Lấy trọng số (weights) đã được huấn luyện sẵn từ mô hình ViHATET5 (đã qua pre-train trên VOZ-HSD) làm điểm bắt đầu.
  - Cấu hình tham số: tối ưu bằng Adam, epochs: 4, max length: 256, lr: 5×10^{-3}, batch size: 32.

Bước 3: Huấn luyện mô hình

Giai đoạn 2: Fine-tuning đa nhiệm (Unified Multi-task)

- **Nhóm thực hiện:**
  - Lấy trọng số (weights) đã được huấn luyện sẵn từ mô hình ViHATET5 (đã qua pre-train trên VOZ-HSD) làm điểm bắt đầu.
  - Cấu hình tham số: tối ưu bằng Adam, epochs: 4, max length: 256, lr: 5×10^{-3}, batch size: 32 (giống hoàn toàn tác giả).
  - Thực hiện huấn luyện trên GPU P100 và H200.

Nội dung báo cáo

1. Giới thiệu tổng quan
2. Phương pháp thực nghiệm
3. **Kết quả thực nghiệm**
4. Phân tích và thảo luận
5. Tài liệu tham khảo

Kết quả thực nghiệm

Bảng 5: Bảng 5: Kết quả sau huấn luyện của các chiến lược

Mô hình	Nguồn dữ liệu	ViHSD	ViCTSD	ViHOS	AVG
VIHATET5	Bài báo (584,495 samples)	0.6548	0.6134	0.8542	0.7075
	Nhóm tái lập (100,000 samples)	0.6808	0.6586	0.8541	0.7312
VIHATET5	Bài báo (1,168,990 samples)	0.6600	0.6022	0.8577	0.7066
	Nhóm tái lập (200,000 samples)	0.6698	0.7189	0.8616	0.7501
VIHATET5	Bài báo (10,747,733 samples)	0.6867	0.7358	0.8644	0.7623
	Nhóm không tái lập				

Kết quả thực nghiệm

Bảng 6: Kết quả sau huấn luyện so với các mô hình có kiến trúc Text-to-Text

Mô hình	Nguồn	ViHSD	ViCTSD	ViHOS
VIHATET5	Bài báo	0.6867	0.7358	0.8644
ViT5	Bài báo	0.6695	0.6482	0.8690
	Nhóm tái lập	0.6625	0.7163	0.8612
mT5	Bài báo	0.6676	0.6993	0.8660
	Nhóm tái lập	0.6246	0.7053	0.8501

Kết quả thực nghiệm

Bảng 7.1: Kết quả sau huấn luyện so với các mô hình thuộc kiến trúc BERT

Mô hình	**Nguồn**	**ViHSD**	**ViCTSD**	**ViHOS**
BERT (cased)	Bài báo	0.6444	0.6710	0.7637
	Nhóm tái lập	0.6427	0.6886	0.8832
XLM-RoBERTa	Bài báo	0.6508	0.7153	0.8133
	Nhóm tái lập	0.6544	0.7231	0.8878
PhoBERT_v2	Bài báo	0.6660	0.7139	0.7351
	Nhóm tái lập	0.6583	0.7304	0.9031
PhoBERT	Bài báo	0.6476	0.7131	0.7281
	Nhóm tái lập	0.6360	0.7210	0.8903

Kết quả thực nghiệm

Bảng 7.2: Kết quả sau huấn luyện so với các mô hình thuộc kiến trúc BERT

Mô hình	**Nguồn**	**ViHSD**	**ViCTSD**	**ViHOS**
BERT (uncased)	Bài báo	0.6292	0.6796	0.7393
	Nhóm tái lập	0.6161	0.6569	0.8706
DistilBERT	Bài báo	0.6334	0.6850	0.7615
	Nhóm tái lập	0.6224	0.6634	0.8706
viBERT	Bài báo	0.6285	0.6765	0.7291
	Nhóm tái lập	0.6149	0.6946	0.8589
ViSoBERT	Bài báo	0.6771	0.7145	0.8604
	Nhóm tái lập	0.6871	0.7483	0.9230
VIHATET5	Bài báo	0.6867	0.7358	0.8637

Nội dung báo cáo

1. Giới thiệu tổng quan
2. Phương pháp thực nghiệm
3. Kết quả thực nghiệm
4. **Phân tích và thảo luận**
5. Tài liệu tham khảo

Tại sao VIHATET5 đạt kết quả vượt trội?

- **Thấu hiểu Mạng xã hội (Domain Match):** Khai phá 10.8M bình luận thực tế từ VOZ để hiểu teencode và từ lóng.
- **Tư duy Logic tự nhiên (Text-to-Text):** Thay vì phân loại bằng vector khô khan, mô hình "suy luận" và sinh nhãn trực tiếp.
- **Sức mạnh hợp lực (Unified Synergy):** Xóa bỏ sự phân mảnh bằng cách hợp nhất "3 bài toán trong 1 bộ não".

Hạn chế của mô hình

- **Ngôn từ mỉa mai, ẩn ý:** Khó nhận diện các câu công kích gián tiếp không chứa từ ngữ nói tục.
- **Ngữ cảnh hội thoại:** Hạn chế khi xử lý các bình luận phụ thuộc vào bình luận cha hoặc luồng thảo luận.
- **Từ vựng biến động (OOV):** Rủi ro bỏ lỡ các từ lóng, teencode mới phát sinh sau giai đoạn thu thập dữ liệu.

Định hướng phát triển

- **Nâng cấp quy mô:** Thử nghiệm và tối ưu hóa trên biến thể VIHATET5-Large.
- **Xử lý ngữ cảnh (Context-aware):** Nghiên cứu kiến trúc phân tích theo luồng hội thoại (thread-level).
- **Triển khai thực tế:** Tích hợp hệ thống kiểm duyệt thời gian thực trên các nền tảng Facebook, TikTok.
- **Học tập liên tục:** Xây dựng cơ chế cập nhật dữ liệu định kỳ để bắt kịp xu hướng ngôn ngữ mạng.

Nội dung báo cáo

1. Giới thiệu tổng quan
2. Phương pháp thực nghiệm
3. Kết quả thực nghiệm
4. Phân tích và thảo luận
5. **Tài liệu tham khảo**

Tài liệu tham khảo (1/2)

Raffel, C., et al. (2020). Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer. *Journal of Machine Learning Research*, 21(140), 1-67. https://arxiv.org/abs/1910.10683

Hugging Face. (2024). T5: Text-To-Text Transfer Transformer. *Transformers Documentation*. https://huggingface.co/docs/transformers/v4.47.1/model_doc/t5

Google Research. (2019). Exploring Transfer Learning with T5: the Text-to-Text Transfer Transformer. *Google Research Blog*. https://research.google/blog/exploring-transfer-learning-with-t5-the-text-to-text-transfer-transformer/

Xue, L., et al. (2021). mT5: A Massively Multilingual Pre-trained Text-to-Text Transformer. arXiv:2010.11934.

Phan, T. H., et al. (2022). ViT5: Pretrained Text-to-Text Transformer for Vietnamese. *COLING 2022*, 4029-4041.

Devlin, J., et al. (2019). BERT: Pre-training of Deep Bidirectional Transformers. *NAACL-HLT 2019*, 4171-4186.

Nguyen, D. Q., & Nguyen, A. T. (2020). PhoBERT: Pre-trained language models for Vietnamese. *Findings of EMNLP*, 1035-1046.

Tài liệu tham khảo (2/2)

Nguyen, L. T., & Luu, K. V. (2023). ViSoBERT: A Pre-trained Model for Vietnamese Social Media Text. *Findings of ACL 2023*, 8095-8108.

Luu, K. V., et al. (2021). ViHSD: Hate Speech Detection for Vietnamese Social Media Text. *ALTA 2021*, 58-68.

Nguyen, P. H., & Luu, K. V. (2021). ViCTSD: Vietnamese Constructive and Toxic Speech Detection Dataset. *WASSA 2021*, 213-223.

Hoang, M., et al. (2023). ViHOS: Hate Speech Spans Detection for Vietnamese. *EACL 2023*, 641-652.

Caselli, T., et al. (2021). HateBERT: Retraining BERT for Abusive Language Detection. *WOAH 2021*, 17-25.

Nguyen, L. T. (2024). VIHATET5: Enhancing Hate Speech Detection in Vietnamese. *ACL 2024 Findings*.

Conneau, A., & Lample, G. (2019). Cross-lingual Language Model Pretraining. *NeurIPS*, 32.

THANK YOU